

是否涉密	否
------	---

桂林电子科技大学
研究生学位论文开题报告表
(专业学位硕士)

学 号： 24032307046

姓 名： 廖锡粤

论 文 题 目： 分组密码
智能化检测系统设计与分析

企业导师姓名： 韦博华

学校导师姓名： 韦永壮

专 业 名 称
(或工程领域)： 网络与信息安全

所 属 学 院： 计算机与信息安全学院

研究生院制表
2025 年 12 月 6 日填

填 表 说 明

1. 研究生须认真填写本表相关内容。
2. 凡所列栏目内容填写不够的，可以另加附页。
3. 本表须保持原格式不变，纸张限用 A4，装订要整齐。

页面设置（页边距为上、下：2.5cm，左为2.6cm，右为2.1cm；字体为宋体小四，行间距为18磅。

一、学位论文研究内容

学号：24032307046		姓名：廖锡粤		研究方向：密码技术与工程	
拟定学位论文题目		分组密码智能化检测系统设计与分析			
学位论文的课题来源（请在相应栏目打√）：					
☐973、863 项目☐国家社科规划、基金项目☐教育部人文、社会科学研究项目 ☐国家自然科学基金☐中央国家其他部门☐国际合作研究项目 ☐与港澳台合作研究项目☐国防项目☐企事业单位委托项目 ☐省（自治区、直辖市）项目☐外资项目☐学校自选项目 ☐非立项☒其他					
学位论文类型： ☐基础研究☒应用研究☐综合研究☐其它					
学位论文研究内容	随着数字化与网络化的深度融合，数据安全防护的需求日益迫切，分组密码作为保障数据机密性与完整性的核心算法，其安全性评估已成为密码领域的关键研究课题。检测分组密码加密结果是否足够随机，直接决定密码算法抵御攻击的能力上限。自神经网络技术引入密码分析领域后，相关研究虽取得突破，但相比较传统的随机性检测套件 SP 800-22(美国国家标准与技术研究院（NIST）发布的随机性测试标准),深度学习应用在分组密码检测仍面临工具碎片化、评估体系不完善的问题。 目前关于深度学习应用于分组密码的检测主要有两种技术，一种是神经网络区分器：通过密码分析方法构建数据集，数据集为二分类任务，以差分任务的神经网络为例：真实样本是定义的差分路径，随机样本是随机生成的差分路径，通过神经网络进行二分类任务区分；另一种是神经网络密文输出预测攻击：通过预测生成密文比特位判断加密算法扩散到随机的临界轮数。 本课题旨在融合深度学习技术与分组密码相关密码分析理论，构建一套基于深度学习的智能化检测系统，研究的的密码算法以分组密码为检测对象，重点完善深度学习在分组密码的检测。主要研究内容如下： 1. 分组密码算法结构特性的神经网络区分器研究。针对 ARX、SPN、Feistel 等主流分组密码结构在轮函数设计、扩散方式与代数特性上的本质差异，系统研究不同密码结构在残差网络（ResNet）、时间序列网络（RNN/LSTM）及基于自注意力机制（Transformer）等深度学习架构下的区分效果差异。通过大量实验数据分析，深入探究各类神经网络对不同密码结构的特征提取能力与适应偏好，构建"密码结构特征-神经网络架构偏好"的映射关系，为每类分组密码结构匹配最优的神经网络区分器。构建起分组密码神经网络区分器检测体系框架。 2. 分组密码神经网络密文输出预测攻击方法研究。针对神经网络密文输出预测攻击方法，通过训练不同架构的深度学习模型（残差网络、时间序列网络、Transformer 等）预测分组密码的密文输出比特，系统研究各类神经网络在预测精度、收敛速度及泛化能力上的差异。重点对比分析不同神经网络架构达成随机猜测的临界攻击轮数差异，基于大规模实验结果建立"神经网络架构-临界轮数"的对应关系，从而构建起基于				

密文预测能力的分组密码安全边界动态评估体系，为密码算法的安全轮数设计与安全性量化评估提供理论支撑与实验依据。

3. 一体化检测平台实现研究。针对分组密码的深度学习检测平台，搭建一套完善的分组密码智能化检测系统，系统采用模块化前后端架构，后端统筹管理多神经网络、数据集构建、分组密码算法等模块，前端搭建直观易用的 Web 可视化界面，构建全流程智能化稳定检测平台。

二、学位论文研究依据

学位论文的选题依据和研究意义，以及国内外研究现状和发展态势，附主要参考文献

2.1 选题依据和研究意义

分组密码是信息安全领域的核心基础算法，基于深度学习的安全性评估已成为密码领域的关键研究课题。根据综述《6 Years of Neural Differential Cryptanalysis》^[2]，自 2019 年 Gohr 提出差分神经网络区分器以来^[3]，6 年间研究已覆盖 24 类对称密码原语，但现有检测手段存在三大核心问题：一是工具碎片化，传统检测是依赖 SP800-22 统计测试套件等传统方法^[4]，神经网络检测器则分散为 ND_Gohr、DBitNet^[16]等独立模型，无统一集成平台；二是分组密码算法结构特性的神经网络区分器研究不足，目前；三是评估维度单一，多数研究仅以神经网络区分器作为分组密码检测指标，缺少对神经网络输出预测攻击的评估研究^[43]。在此背景下，构建分组密码架构特性的神经网络区分器、增加以神经网络输出预测攻击的评估指标、支持工程化全流程检测的一体化系统，已成为密码测评与算法研发领域的迫切需求。

构建适配分组密码架构特性的神经网络区分器、增设输出预测攻击评估指标及研发一体化检测系统的研究具有重要意义，丰富算法结构与深度学习模型适配性研究，丰富深度学习驱动的密码安全评估理论体系。为目前分组密码的基于深度学习检测提供一个平台，为密码算法研发与测评机构提供有力技术支撑。

2.2 国内外研究现状

2.2.1 神经网络区分器的研究现状

神经差分密码分析作为 AI 赋能密码学的新兴交叉方向，其系统性研究始于 2020 年后。早在 2019 年，Gohr 首次将深度学习引入差分分析，揭示了神经区分器在轻量级密码中的潜力^[3]，启发了后续神经区分器研究。

2021 年，领域进入理论深化期：Bellini 等通过系统性对比证实 CNN、MLP 在轻量级密码分析中显著优于传统区分器^[4]；Benamira 等剖析 Gohr 模型内在机制，发现其学习的是“差分 - 线性混合特征”^[5]，为特征设计提供理论支撑；Bao 等提出“条件差分-神经密码分析”框架，通过约束明文/密钥比特将 SPECK/SIMON 攻击轮次推进至 13/16 轮^[6]，确立神经-经典混合攻击范式。

2022-2023 年，研究聚焦技术优化与自动化：Bacuiet 等基于“彩票假设”实现 SPECK 区分器 10 倍参数压缩^[8]，开启模型轻量化方向；Ebrahimi 等提出 8 比特部分区分器，在 6 轮 SPECK 上降低 75%数据与计算成本^[9]；Bellini 等提出密码无关的 DBitNet 训练流水线，支持 8 种密码自动生成区分器，提出密码无关的通用设计模式^[11]；Hambitzer 等开发 NNBits 工具，实现神经区分器比特级行为解释^[12]，破解模型精度来源之谜。可解释 AI 技术（LIME/SHAP）的引入进一步提升了模型可解释性，7 轮 SPECK32 精度达 61.69%^[13]。

2024-2025 年，研究向大状态与标准化算法攻坚：Li 等提出改进的深度学习辅助密钥恢复框架，通过学生区分器集成实现 18 轮 SIMON128 和 12 轮 SPECK128 攻击，突破大状态密码瓶颈^[15]；Zhang 等首次将神经差分分析应用于 AES，训练 2 轮字节对区分器并恢复 3 轮 AES-128 密钥^[16]，填补该领域空白；Zhu 等提出 BCS 方法，基于非线性组件不确定性优化 PRESENT 攻击，精度达 52.08%^[17]；Hu 等通过部分差异比特泄露技术，在 7 轮 SPECK32 上实现 65%精度并降低 40%计算资源^[18]，适配物联网场景需求。

2.2.2 神经网络区分器优化实现的研究现状

模型优化方向聚焦“轻量化-数据集高效化-架构创新”，核心目标是降低计算与数据成本，提升工程化适用性。

模型轻量化方面，2022 年彩票假设证实 10 层 CNN 可压缩至 1 层而无性能损失^[8]；2023 年刘等提出基于知识蒸馏的轻量化框架，构建小型学生网络实现 13-14 轮 SPECK 攻击，计算成本降低 60%^[19]；Ebrahimi 等针对 AND-RX 结构优化的旋转异或区分器，使 11 轮 SIMON32 精度达 54.45%^[22]，验证了结构专用架构的优势。

数据集优化方面，2022 年部分 ML 检测器通过比特选择降低加密查询^[9]；2024 年 Shen 等提出 PCA-Kmeans 质量优化方法，使 7 轮 SPECK32 训练样本减少 25%^[20]，显著提升训练效率。

架构创新方面，Sajwan 等对比 ResNet 与 DenseNet，发现短轮数下 DenseNet 有边际优势但易过拟合^[21]；集成学习技术通过融合多模型预测，有效降低过拟合风险^[14]；注意力机制的引入进一步提升了 SPECK32 区分器精度至 61.69%^[13]，为架构设计提供新思路。

2.2.3 神经网络输出预测攻击研究现状

神经网络输出预测攻击作为分组密码脆弱性检测的重要补充技术，核心聚焦“黑盒环境下明文-密文对驱动的输出建模”，研究脉络从结构覆盖走向针对性优化。

2021 年，葛钊成等在《密码学报》发表综述，明确输出预测攻击“无需专家密码分析知识即可定位结构缺陷”的核心优势，为该方向系统性发展提供理论参照^[27]。2022 年，Kimura 等发表里程碑式研究，首次将 LSTM 模型系统应用于输出预测攻击，构建 2^{15} 规模数据集，成功覆盖 SPN（small PRESENT、AES-like）与 Feistel（TWINE-like）结构，实现黑盒环境下的密文预测与明文恢复^[28]，并发现密码内部组件替换对攻击成功率的专属影响，为抗深度学习密码设计提供核心靶点。

2024 年后，研究向非 SPN 结构拓展：Watanabe 等将输出预测攻击应用于 AND-Rotation-XOR 结构的 Simon 密码，发现“扩散特性不足与核心函数偏置输出”是攻击成功的关键，填补了非 S 盒结构密码攻击的空白^[29]。2025 年，Singh 提出基于 MLP 的轮式仿真框架，对 PRESENT 的 SPN 结构进行独立轮建模，在不降低攻击效果的前提下

优化训练效率与针对性^[30]，推动技术向实用化场景渗透。

2.3 存在的科学问题

根据上面的国内外发展情况，结合现阶段研究，总结以下一些问题：

- (1) 缺少分组密码算法结构特性的神经网络区分器。ARX 类密码（SPECK/SIMON）分析技术成熟，但 SPN 结构（AES/PRESENT）神经差分分析刚起步^{[16][18]}，Feistel 结构（如 DES）缺乏系统性神经检测研究^[34]，三类核心密码结构的检测模型设计呈现碎片化特征，未能建立基于“结构特征-架构参数”映射的专用网络构建。
- (2) 检测工具碎片化，全流程一体化平台缺失。现有神经检测器分散为 ND_Gohr、DBitNet、NNBits 等独立模型，无统一集成框架导致复用困难、评估标准不一^{[11][12]}。缺少集成这些模型的检测工具。
- (3) 神经网络输出预测攻击维度单一，轮间动态演化捕捉不足。当前神经网络输出预测攻击主要聚焦“明文 - 最终密文”的端到端映射建模^{[28][29]}，未能充分捕捉密文在多轮迭代过程中的动态演化规律，缺乏针对“上一轮密文→下一轮密文”的轮间预测研究。该缺口导致攻击仅能依赖最终输出的统计特征，难以挖掘轮函数内部的结构脆弱性（如扩散不完全、非线性组件偏置），进而限制了攻击深度与跨结构泛化能力，无法为密码算法的轮函数优化设计提供精准反馈。

2.4 参考文献

- [1] National Institute of Standards and Technology (NIST). A Statistical Test Suite for Random and Pseudorandom Number Generators for Cryptographic Applications. NIST Special Publication 800-22, Revision 1a, 2010.
- [2] Gerault D, Hambitzer A, Huppert M, et al. Survey: 6 Years of Neural Differential Cryptanalysis [J]. 2025.
- [3] Gohr A. Improving attacks on round-reduced speck32/64 using deep learning[C]//CRYPTO 2019. Springer, 2019: 150-179.
- [4] Bellini E, Rossi M. Performance comparison between deep learning-based and conventional cryptographic distinguishers[C]//Computing Conference 2021. Springer, 2021: 681-701.
- [5] Benamira A, et al. A deeper look at machine learning-based cryptanalysis[C]//EUROCRYPT 2021. Springer, 2021: 805-835.
- [6] Bao Z, et al. Enhancing differential-neural cryptanalysis[C]//ASIACRYPT 2021. Springer, 2021: 318-347.
- [7] Su H C, et al. Polytopic attack on round-reduced simon32/64 using deep learning[C]//Inscrypt 2020. Springer, 2021: 3-20.
- [8] Bacuiet N, et al. Deep neural networks aiding cryptanalysis: A case study of the speck distinguisher[C]//ACNS 2022. Springer, 2022: 809-829.
- [9] Ebrahimi A, et al. Reducing the cost of machine learning differential attacks using bit selection and a partial ml-distinguisher[C]//FPS 2022. Springer, 2022: 123-141.
- [10] Liu D, et al. The construction and application of (related-key) conditional differential

- neural distinguishers on katan[C]//CANS 2022. Springer, 2022: 203-224.
- [11] Bellini E, et al. A cipher-agnostic neural training pipeline with automated finding of good input differences[J]. IACR ToSC, 2023, 3: 184-212.
- [12] Hambitzer A, et al. Nnbits: Bit profiling with a deep learning ensemble based distinguisher[C]//CT-RSA 2023. Springer, 2023: 493-523.
- [13] Goi Y T, et al. Unveiling the black box: Neural cryptanalysis with xai[C]//IEEE SMC 2024. IEEE, 2024: 1951-1956.
- [14] Chen Y, et al. A new neural distinguisher considering features derived from multiple ciphertext pairs[J]. The Computer Journal, 2023, 66: 1419-1433.
- [15] Zhang L, et al. Improved differential-neural cryptanalysis for round-reduced simeck32/64[J]. Frontiers of Computer Science, 2023, 17: 176817.
- [16] Zhang L, et al. Differential-neural cryptanalysis on AES[J]. IEICE Trans. Inf. Syst., 2024, 107: 1372-1375.
- [17] Zhu S, et al. Bcs: A neural distinguisher method based on differential propagation uncertainty of nonlinear components and network adaptability[J]. Physica Scripta, 2025.
- [18] Hu Y, et al. Enhancing neural distinguishers with partial difference bits leakage[J]. Internet Things, 2025, 29: 101438.
- [19] Liu J, et al. A deep learning aided differential distinguisher improvement framework with more lightweight and universality[J]. Cybersecurity, 2023, 6: 47.
- [20] Shen D, et al. A novel approach to construct a good dataset for differential-neural cryptanalysis[J]. IEEE TDSC, 2024.
- [21] Sajwan A, Mishra G. Comparative analysis of resnet and densenet for differential cryptanalysis of speck 32/64[C]//CNSML 2023. Springer, 2023: 495-504.
- [22] Ebrahimi A, et al. Deep learning-based rotational-xor distinguishers for and-rx block ciphers[C]//SAC 2023. Springer, 2023: 429-450.
- [23] 冯登国, 张锐, 张文涛. 深度学习辅助密码分析:现状与展望[J]. 软件学报, 2023, 34(5): 2098-2115.
- [24] 李子臣, 杨阳. SM4 算法的神经差分攻击研究[J]. 电子与信息学报, 2022, 44(12): 4021-4030.
- [25] 吴文玲, 张蕾, 张健. 基于多差分特征融合的密码分析[J]. 密码学报, 2023, 10(5): 489-502.
- [26] MISHRA S, PATHAK A, SINGH A. Neural network based full round PRESENT cipher attack[R]. IACR Cryptology ePrint Archive, 2019: 783.
- [27] 葛钊成, 胡汉平. 神经网络与密码学的交叉研究 [J]. 密码学报, 2021, 8 (2): 215-231. DOI: 10.13868/j.cnki.jcr.000432.
- [28] KIMURA H, EMURA K, ISOBE T, et al. Output prediction attacks on block ciphers using deep learning[R]. IACR Cryptology ePrint Archive, 2022: 1724.
- [29] WATANABE H, ITO R, OHIGASHI T. On the effects of neural network-based output

prediction attacks on the design of symmetric-key ciphers[C]//Proceedings of the 8th International Symposium on Cyber Security, Cryptology and Machine Learning (CSCML 2024). Cham: Springer, 2024: 321-340. DOI: 10.1007/978-3-031-76934-4_18.

[30] SINGH G. Present full round emulation: structural flaws and predictable outputs[R]. IACR Cryptology ePrint Archive, 2025: 1069.

三、学位论文研究方案及研究计划

1、研究方案（包括有关理论、方法、技术路线、创新手段、关键技术等）

3.1 有关理论

3.1.1 分组密码基础理论

分组密码是对称密码学的核心分支，其本质是将明文按固定长度（分组长度）划分为若干块，通过可逆的密钥控制变换，将每块明文独立映射为等长密文的加密算法。作为信息安全领域的基础技术，分组密码广泛应用于数据加密、密钥交换、消息认证等场景，其设计与分析是密码学研究的核心方向之一。

分组密码的核心特征：明文/密文块长度固定（记为 n 比特），加密解密使用同一密钥（对称特性）。

分组密码的设计需遵循香农提出的核心准则，同时结合现代密码分析技术优化，确保安全性与效率的平衡：（1）混淆：通过非线性变换使密文与密钥的关系复杂化，隐藏明文与密文的直接关联。例如，S 盒是实现混淆的核心组件，通过非线性映射破坏数据的统计规律；（2）扩散：将明文的每一位信息均匀扩散到密文的所有位，使单个明文位的变化影响多个密文位。例如，置换、移位、线性变换（如 AES 的 MixColumns）均为扩散手段；（3）抗攻击能力：抵御差分密码分析、线性密码分析、积分密码分析、不可能差分分析等经典攻击，同时需考虑深度学习等新型攻击；（4）效率：硬件实现（面积、功耗）和软件实现（速度、内存占用）高效，适配嵌入式设备、服务器等不同场景；（5）可扩展性：分组长度、密钥长度支持灵活配置（如 AES 支持 128/192/256 位密钥）；（6）简单性：算法结构清晰，避免冗余设计，降低实现错误风险。

分组密码的迭代结构决定了其安全性与效率，以下是三种最具代表性的框架：

Feistel 结构原理:(1)将明文块($p = (L_0, R_0)$)分为左右两部分（长度均为 $(n/2)$ 比特）；(2)迭代 r 轮，第 i 轮变换为： $(L_i = R_{i-1}, R_i = L_{i-1} \oplus F(R_{i-1}, K_i))$ 其中(K_i)为轮密钥（由主密钥通过密钥扩展算法生成）， F 为轮函数；(3)最后一轮输出 $((R_r, L_r))$ ，作为密文块（或需额外置换）。Feistel 结构如图 1 所示。




图 1Feistel 结构图

SPN 结构原理:(1)密钥混合 (AddRoundKey)：将轮密钥与当前状态异或；(2)替代层 (S-Layer)：通过多个并行的 S 盒对状态进行非线性变换（混淆）；(3)置换层 (P-Layer)：对替代层输出进行

线性置换（扩散），使单个 S 盒的输出影响多个 S 盒的输入。Feistel 加密结构如图 2 所示。




图 2SPN 结构图

Lai-Massey 结构原理：（1）数据划分：将输入状态划分为左、右两个等长的部分，记为 (L_{i-1}, R_{i-1}) ；（2）轮函数处理：对当前轮密钥 K_i ，计算轮函数 F 作用于左右两半的异或值，即 $Y = F(L_{i-1} \oplus R_{i-1}, K_i)$ ；（3）状态更新：将原右半部分 R_{i-1} 与轮函数输出 Y 异或得到新右半部分 $R_i = L_{i-1} \oplus Y$ ，同时将左半部分 L 与轮函数输出 Y 异或得到新的左半部分 $L_i = L_{i-1} \oplus Y$ ；（4）轮交换：输出 (L_i, R_i) 作为下一轮的输入。Lai-Massey 加密结构如图 3 所示。




图 3Lai-Massey 结构图

3.1.2 深度学习相关理论

深度学习的高效应用与模型构建，离不开坚实的核心理论作为支撑。这些理论从数学基础、训练方法、参数优化到有效性保障等关键维度，为深度学习的可行性与实用性提供了根本依据。

万能逼近定理是深度学习有效性的核心数学保障，其核心结论为：在激活函数满足非多项式且连续温和条件下，单隐藏层的多层感知机（MLP）可以任意精度逼近定义在紧致集上的连续函数。数学表达为：设 $(f: \mathbb{K}^n \rightarrow \mathbb{K}^m)$ 为紧致集 $(K \subseteq \mathbb{K}^n)$ 上的连续函数（ $(\mathbb{K})$ 为实数域或复数域），则对任意 $(\epsilon > 0)$ ，存在正整数 (L) 、权重 $(w_i \in \mathbb{K}^n)$ 、偏置 $(b_i \in \mathbb{K})$ 及输出权重 $(v_i \in \mathbb{K}^m)$ ，使得：

$$\sup_{x \in K} \left\| f(x) - \sum_{i=1}^L v_i \sigma(w_i^T x + b_i) \right\| < \epsilon$$

其中 $(\sigma(\cdot))$ 为激活函数（如 ReLU、Sigmoid）。该定理证明了神经网络无需依赖手工设计特征，即可拟合复杂非线性关系，为深层模型的构建提供了理论依据。

前向传播是神经网络实现数据映射与特征转换的基础理论，核心思想是将输入数据通过网络各层的线性变换与非线性激活，逐层传递至输出层，最终得到预测结果，是后续反向传播优化的前提。其本质是多层函数的嵌套计算，清晰定义了网络从输入到输出的数据流路径。数学表达上，设输入层数据为 $(x = a_0 \in \mathbb{R}^{d_0})$ （ (d_0) 为输入维度），第 (k) 层（共 (L) 层）的权重矩阵为 $(w_k \in \mathbb{R}^{d_k \times d_{k-1}})$ 、偏置为 $(b_k \in \mathbb{R}^{d_k})$ 、激活函数为 $(\sigma_k(\cdot))$ ，则前向传播过程可递推表示为：

$$\begin{aligned} z_k &= w_k a_{k-1} + b_k \\ a_k &= \sigma_k(z_k) \end{aligned}$$

其中 (z_k) 为第 (k) 层的线性输入（预激活值）， (a_k) 为第 (k) 层的输出（激活后特征），最终输出层结果为 (a_L) （即模型预测值）。该理论明确了神经网络的核心计算流程，是连接输入数据与模型输出的关键，也为后续反向传播中梯度的追溯提供了清晰的计算链路。

反向传播是深层神经网络参数优化的核心方法，其本质是利用链式法则高效计算损失函数对 layers 参数的梯度，为梯度下降优化提供基础。设神经网络的损失函数为 $(\mathcal{L}(\theta))$ （ $(\theta = \{w_1, b_1, w_2, b_2, \dots, w_L, b_L\})$ 为所有层的权重和偏置），前向传播中第 (k) 层的输入为 $(z_k = w_k a_{k-1} + b_k)$ ，输出为 $(a_k = \sigma(z_k))$ （ $(a_0 = x)$ 为输入数据）。则损失函数对第 (k) 层权重 (w_k) 和偏置 (b_k) 的梯度计算为：

$$\frac{\partial \mathcal{L}}{\partial w_k} = \delta_k a_{k-1}^T, \frac{\partial \mathcal{L}}{\partial b_k} = \delta_k$$

其中误差项 (δ_k) 按反向递推计算：输出层 $(\delta_L = \nabla_{a_L} \mathcal{L} \odot \sigma'(z_L))$ ，隐藏层 $(\delta_k = (w_{k+1}^T \delta_{k+1}) \odot \sigma'(z_k))$ （ $(\odot)$ 为逐元素乘积）。通过该算法，梯度计算复杂度从指数级降至线性级，使深层模型的训练具备工程可行性。

梯度下降是利用反向传播计算的梯度调整模型参数、最小化损失函数的核心优化方法。其核心思想是沿损失函数梯度的反方向迭代更新参数，逐步逼近最优解。参数更新的通用公式为：

$$\theta_{t+1} = \theta_t - \eta \cdot \nabla_{\theta} \mathcal{L}(\theta_t)$$

其中 (θ_t) 为第 (t) 轮迭代的参数， $(\eta > 0)$ 为学习率（控制步长）， $(\nabla_{\theta} \mathcal{L}(\theta_t))$ 为损失函数在当前参数下的梯度。为平衡收敛速度与稳定性，衍生出小批量梯度下降（Mini-batch SGD）、Adam 等改进

算法，其中 Adam 结合动量与自适应学习率，公式为：

$$m_t = \beta_1 m_{t-1} + (1 - \beta_1) \nabla_{\theta} \mathcal{L}(\theta_t), v_t = \beta_2 v_{t-1} + (1 - \beta_2) \left(\nabla_{\theta} \mathcal{L}(\theta_t) \right)^2$$

$$\hat{m}_t = \frac{m_t}{1 - \beta_1^t}, \hat{v}_t = \frac{v_t}{1 - \beta_2^t}, \theta_{t+1} = \theta_t - \eta \cdot \frac{\hat{m}_t}{\sqrt{\hat{v}_t} + \epsilon}$$

（ (β_1, β_2) 为动量衰减系数， (ϵ) 为防止分母为 0 的微小值），成为深度学习中应用最广泛的优化器。

泛化能力指模型在未见过的测试数据上的表现，正则化是防止过拟合（训练误差小而测试误差大）、提升泛化能力的核心手段。其本质是通过约束模型复杂度或引入先验信息，降低泛化误差。最常用的正则化方法包括 L2 正则化（权重衰减），此时损失函数修正为：

$$\mathcal{L}_{\text{reg}}(\theta) = \mathcal{L}(\theta) + \frac{\lambda}{2} \sum_{i,j} w_{i,j}^2$$

其中 $(\lambda > 0)$ 为正则化强度，通过惩罚权重的平方和，使参数值趋于平缓，减少模型对训练数据噪声的依赖。此外，Dropout 通过训练时随机丢弃部分神经元（概率 (p) ）实现正则化，测试时对权重缩放 $(1 - p)$ ，等价于多个简化模型的集成，有效降低了模型的过拟合风险，保障了深度学习模型在实际场景中的可用性。

3.2 技术路线

针对目前分组密码的智能化检测（不同密码结构与区分器适配性不足、检测方法过少缺乏成熟检测平台），整体技术路线分为三步、逐层递进（如图 5 所示）：

第一步，聚焦核心研究目标，开展基础层研究工作：针对 ARX、SPN、Feistel 等组密码的结构特性，分析其与神经网络架构的适配关联，完成分组密码神经网络区分器的优化实现。

第二步，优化分组密码的神经网络输出预测攻击检测方法，完善密码检测技术体系并验证有效性。

第三步，搭建一体化密码检测平台，完成前后端模块化架构的构建，实现多神经网络区分器的调度管理、检测流程监控及可视化展示等功能；同时结合密码分析技术进一步优化流程，构建适配不同密码结构的神经网络并开展训练验证，最终实现全流程的高效协同，提升密码神经网络区分器的实用性。这一步对应研究内容中“一体化检测平台实现”的任务，借助平台模块搭建、网络训练验证等方法完成落地。




图 5 研究技术路线图

3.3 创新手段

1. 分组密码算法结构的神经网络区分器匹配策略

针对 ARX、SPN、Feistel 等主流分组密码在轮函数设计、扩散机制及代数特性上的本质差异，突破传统单一神经网络架构的应用局限。通过系统解析不同密码结构的特征表达规律（如 SPN 的线性 / 非线性变换分离特性、Feistel 的对称迭代特性、ARX 的模运算累加特性），构建“密码结构特征-神经网络架构偏好”的映射规则。基于 ResNet 的残差特征传播优势、RNN/LSTM 的序列依赖建模能力、Transformer 的全局注意力捕捉特性，实现对不同密码结构的最优神经网络架构自适应匹配。

2. 神经网络输出预测攻击优化

针对传统输出预测攻击“明文 - 最终密文”直接映射的局限，结合分组密码“多轮迭代、逐轮扩散”的核心特性，重构“中间轮状态 - 下一轮状态”的迭代预测模式。通过捕捉密文在轮间的动态演化规律，选用 RNN/LSTM、带门控机制的 Transformer 等适配序列建模的架构，精

准挖掘轮函数内部脆弱性，提升临界轮数预测精度与攻击深度，完善分组密码安全性评估的维度与有效性。

3. 一体化智能检测平台构建

突破深度学习分组密码检测工具模块割裂、流程碎片化，创新设计模块化前后端协同架构，构建全流程闭环的分组密码智能化检测平台。后端研发统一调度核心模块，实现多类型神经网络模型（ResNet、RNN/LSTM 等）、自适应数据集构建、主流分组密码算法（ARX/SPN/Feistel）等核心组件的统筹管理与灵活适配调用；前端创新搭建可视化交互界面，支持检测任务一键配置、实时进度追踪、实验数据可视化分析（区分效果曲线、临界轮数对比等）全流程操作，为分组密码安全性检测提供高效、稳定、可复用的一体化技术支撑平台。

3.4 关键技术

3.4.1 神经网络架构设计

神经网络架构作为分组密码深度学习区分器的核心支撑，其设计合理性直接决定模型对密码数据二进制特性、局部迭代规律及非线性扩散特征的捕捉能力，是影响区分精度、训练稳定性与工程化部署效率的关键因素。

1. 卷积神经网络（CNN）

CNN 是神经网络最常用的基础架构，核心优势是捕捉数据的局部相关性（如 SPN 结构的 S 盒替换、线性扩散层，ARX 结构的模加/异或操作）。标准卷积层：Conv1d（处理一维明文/密文序列）、Conv2d（将二进制序列 reshape 为二维矩阵，适配 S 盒的二维替换特性）——例如 ND_Gohr 区分器采用 Conv2d 提取 AES 密文的局部非线性特征；空洞卷积（Dilated Conv）：扩大感受野而不增加参数，捕捉密码多轮迭代后的「长程扩散特征」——例如针对高轮次 AES，空洞卷积可覆盖更多轮次的特征依赖。

2. 残差网络（ResNet）

残差网络（ResNet）是解决深层 CNN 退化问题的核心架构，核心创新为残差块与跳接连接。其核心思想是让网络学习“残差映射”（ $F(x)=H(x)-x$ ）而非直接学习恒等映射，输出为残差支路结果与输入叠加（ $H(x)=F(x)+x$ ），跳接连接可使梯度直接反向传播，缓解梯度消失/爆炸。当维度不匹配时，通过 1×1 卷积适配。ResNet 支持训练数百层甚至千层网络，泛化能力强，能高效拟合分组密码的强非线性变换，是神经网络输出预测攻击、密码分析区分器设计等任务的核心基础模型，兼具深层表达能力与训练稳定性。

3. ND_Gohr 残差卷积架构

Gohr 提出的经典架构，包含比特切片卷积、残差卷积塔、全连接预测头三层结构，通过残差连接解决深层网络梯度消失问题，可有效学习 ARX 类密码（如 SPECK）的差分特征，同时支持深度 1/5/10 的灵活调整，还衍生出剪枝版（ND_Gohr^{pruned}）、注意力增强版（ND_Gohr^{atttn}）等轻量化或增强变体，适配不同密码的检测需求，ND_Gohr 架构如图 6 所示。




图 6 ND_Gohr 残差卷积架构

4. 密码无关通用架构

以 DBitNet 为代表，采用空洞卷积层替代人工设计的比特切片卷积，无需针对密码结构定制输入格式，可自动生成多类密码（SIMON、PRESENT、TEA 等）的区分器，通过简单分阶段训练即可达到与 ND_Gohr 相当的精度，大幅降低技术门槛，架构如图 7 所示。




图 7 密码无关通用架构（DBitNet）

3.4.2 样本工程与特征工程

1. 算法特征导向的样本生成

基于分组密码算法结构（S 盒、线性层等），模拟生成蕴含非随机性特征的正样本（明文 - 密文对、明文 - 中间轮状态对），通过标准化随机源生成同维度负样本，确保样本区分性与代表性。

2. 定向特征工程

采用二进制 - 数值映射、特征归一化（比特归一化 / Z-Score）及密码学先验特征选择，在标准化输入格式的同时，保留算法核心区分特征，适配神经网络输入需求。

3. 均衡泛化增强的样本优化

通过过采样 / 欠采样平衡正负样本比例，结合跨密钥 / 跨轮数样本扩充与对抗性扰动增强，提升样本集泛化能力，降低模型过拟合风险。

3.4.3 密码差分分析

密码差分分析是一种选择明文攻击方法，通过研究明文对差异与对应密文对差异之间的统计关系来恢复密钥。其核心在于构建算法的差分分布特性，搜索高概率差分路径，并设计密钥恢复策略。

1. 差分分布表构建

(1)差分分布表（DDT）生成：针对分组密码的非线性组件（如 S 盒），枚举所有输入差分 Δx 与输出差分 Δy 的组合，统计其转换概率。对 8-bit S 盒需遍历 216 种差分对，对 4-bit S 盒可优化至 28 种组合，构建概率矩阵以刻画非线性变换的差分传播规律。

(2)差分活性追踪：分析线性层（P 盒、位移操作）的差分扩散特性，构建分支数评估模型。通过计算活跃 S 盒数量的下界，评估密码算法抵抗差分攻击的理论强度，为路径搜索提供复杂度预估。

2. 高概率差分路径搜索

(1)自动路径搜索算法：基于广度优先搜索（BFS）或启发式算法，从低轮次向高轮次逐层扩展差分路径。对 SPN 结构采用精确搜索确保概率最优，对 Feistel 结构利用轮函数对称性剪枝，搜索效率较暴力枚举提升 2-3 个数量级。

(2)中间相遇与聚类技术：对高轮次密码采用中间相遇策略，分别从加密端和解密端搜索半路径，在中间轮次进行匹配。通过差分路径聚类将多条相似路径的概率叠加，提升整体区分优势

3. 差分攻击实施与优化

(1)密钥筛选与恢复：基于高概率差分路径构造区分器，选择满足特定差分模式的明文对，分析最后一轮子密钥的候选值。通过计数器统计每个密钥猜测下符合差分对的数量，将计数异常高的密钥作为正确密钥的候选，复杂度由穷举 2^n 降至 2^{n-k} （ k 为优势位数）。

(2)数据复杂度优化：采用结构技术和无偏抛掷技术减少所需明文对数量。通过精心构造明文结构使单个结构产生多对满足条件的差分对，数据复杂度降低至传统方法的平方根级别。

3.4.4 训练策略优化

1. 分阶段预训练

先预训练低轮密码的区分器，再微调高轮模型，或冻结卷积层仅更新预测头，大幅降低高轮密码的训练成本（如 ND_Gohr 对 8 轮 SPECK 的训练）。

2. 模型轻量化与迁移

通过知识蒸馏压缩模型参数（如 ND_Gohr 教师模型→轻量化学生模型，参数减 60% 仍保 95% 精度）、量化训练 / 模型剪枝，适配工程化低算力部署；支持跨密码的特征迁移（将 SIMON

的预训练模型迁移至 SIMECK）。

3. 过拟合抑制与超参数调优

采用 L2 正则化、Dropout 层、早停策略抑制过拟合；通过网格搜索/贝叶斯优化调优学习率（ $1e-4 \sim 1e-3$ ）、批大小（32/64/128）等超参数；利用批量归一化提升训练收敛速度。

2、实验条件落实情况，可能存在的问题及解决办法

(1) 实验条件落实情况

广西密码学与信息安全重点实验室具备 GPU 服务器、密码算法测试平台等软硬件设备，可提供样本生成、模型训练与系统测试的全流程支撑。

(2) 可能存在的问题：

神经网络架构复现存在代码逻辑误差；软硬件交互存在数据速率不匹配问题；分组密码检测效果未达预期；训练时间过长影响检测。

(3) 解决方法：

仔细研究相关理论，查阅并研究最新的相关研究以及相应的开源实现，多进行实验同时进行对比，根据实验结果不断完善方案。

3、年度研究计划		
年度研究计划	起始时间	完 成 内 容
	2024.09-2025.06	完成分组密码与神经网络区分器理论，神经网络密文输出预测攻击调研，梳理系统需求并确定架构。
	2025.07-2025.12	查阅资料，研读论文，确定研究方向，完成开题工作。
	2026.01-2026.07	设计实验框架，完成分组密码智能化检测系统的后端搭建。
	2026.08-2026.12	开发可视化界面与报告生成功能，实现系统完整链路；选取 AES、SM4、SPECK 等分组密码进行系统测试；撰写论文初稿。
	2027.01-2027.06	完善论文内容，准备论文评审与答辩，整理系统代码、软件著作权申请材料。
4. 学位论文创新和预期研究成果		
学位论文创新： （1）提出分组密码算法结构特性的神经网络区分器，实现分组密码区分器的统一检测入口，解决现有工具碎片化问题，且适配传统（AES）与轻量级（SPECK）、国际（AES）与国产（SM4）分组密码，覆盖范围更广。 （2）提出使用神经网络密文输出预测攻击方法进行分组密码检测，完善分组密码的安全性评估。 （3）实现分组密码检测的全流程自动化，从样本生成、区分器训练/加载、多维度评估到报告生成，无需人工干预，大幅提升检测效率。		
预期研究成果： 发表 1 篇学术论文；申请 1 项发明专利；完成硕士论文。		

四、开题报告审查意见

1. 校外导师对学位论文选题、论文计划可行性等方面意见，是否同意开题。

该生选题合理，拟开展的研究技术路线较为合理、可行，同意开题。




签名：  2025年 12月15日

2. 校内导师对学位论文选题、论文计划可行性等方面意见，是否同意开题。

同意

签名：  2025年 12月 15日

3. 评审专家意见


开 题	时间： 2025 年 12 月 25 日	地点： 桂林电子科技大学花江校区慧谷 1 号楼 408
报告会	评审专家（至少 3 位，请专家本人签名）： 答辩主席：  答辩委员会成员：    	

评审专家组意见：

1. 论文选题的理论意义或实用价值： ☒较大 ☐一般 ☐较小
2. 论文难度： ☐偏高 ☒适当 ☐偏小
3. 论文工作量： ☐偏大 ☒适当 ☐偏小
4. 研究方案的可行性： ☒好 ☐较好 ☐一般 ☐不可行
5. 对文献资料及课题的了解程度： ☒好 ☐较好 ☐一般 ☐较差
6. 对开题报告中反映出的综合能力和表达能力： ☐好 ☒较好 ☐一般 ☐较差
7. 是否同意论文开题报告： ☒同意 ☐需要重做

综合考核结果（请划√）：

☐优秀 ☒良好 ☐中等 ☐及格 ☐不合格

组长签名：  2025年 12 月 16 日

4. 学院（所、部）意见：

同意

主管领导签名：

单 位（盖章）

2025年 12月 16 日